



Slovenian Instruction-based Corpus Generation

Gašper Spagnolo, Žiga Klun, Žiga Črv

Abstract

This project explores the utilization of Large Language Models (LLMs) for conversational agent development in the Slovene language. We investigate various state-of-the-art LLMs suitable for fine-tuning, considering factors such as compatibility with Slovene, computational infrastructure requirements, and model capabilities. Emphasis is placed on understanding the creation process of LLMs and the construction of high-quality conversational datasets. Our methodology involves reviewing datasets and categorizing instructions for training Instruct-based LLMs. We devise a comprehensive plan for data gathering, identifying sources such as med-over.net and slo-tech forums. Crawlers are developed to efficiently collect conversational data, which is organized systematically to facilitate fine-tuning of LLMs. Additionally, we examine pertinent literature, including research on models like BLOOM and LLaMa 2, to ascertain key considerations in data preparation. By synthesizing these insights, we prepare a corpus of conversational data tailored for fine-tuning LLMs, ensuring its relevance and quality. Furthermore, we discuss the potential adaptation of an existing LLM using the gathered data, offering insights into the practical application of our methodology. Our findings are consolidated in a final report, providing a comprehensive overview of the process and its implications for developing conversational agents in Slovene using LLMs.

Keywords

Large Language Models (LLMs), Slovene language, fine-tuning, dataset construction, data gathering, data organization, LLaMa 2, MixTal, Med.Over.Net, Viva.bhc.si, Vizita.si

Advisor: Slavko Žitnik

Introduction

Introduction se vedno napise ko končamo z delom, hvala lepa za razumevanje.

Methods

V razvoju konverzijskih agentov, ki delujejo v slovenskem jeziku, se osredotočamo na napredne pristope procesiranja naravnega jezika (NLP). Pomemben del našega raziskovalnega dela predstavlja analiza in prilagoditev dveh sodobnih modelov: LLaMA2 [1] in MixTal [2]; predstavljata temelj za razvoj naših konverzijskih sistemov. Oba modela bomo prilagodili za delovanje v slovenskem jeziku, s posebnim poudarkom na razumevanju in generiranju naravnega, tekočega dialoga.

Za uspešno prilagajanje modelov na slovenski jezik in specifične slovenskega komunikacijskega prostora bomo izvajali "scraping" (pobiranje podatkov) s slovenskih forumov, kot so MedOverNet [3], Vizita [4] in Viva [5]. Ti forumi predstavljajo bogat vir realnih konverzijskih vzorcev in specifičnih izrazov, ki so ključni za razumevanje in ustrezno odzivanje

na povpraševanja uporabnikov. Posebno pozornost bomo namenili selekciji besedil, saj želimo zagotoviti, da bodo odgovori generirani s strani naših konverzijskih agentov temeljili izključno na verodostojnih informacijah, podanih s strani zdravnikov ali specializantov na posameznih področjih. Tak pristop bo zagotovil večjo zanesljivost in kredibilnost odgovorov, kar je še posebej pomembno pri temah, ki so zdravstvene ali strokovne narave.

Prilagajanje modelov, kot sta LLaMA2 in MixTal, za specifične jezikovne in kulturne kontekste predstavlja izziv, a hkrati ponuja obetavne možnosti za razvoj visoko funkcionalnih in prilagodljivih konverzijskih sistemov. Naš cilj je ustvariti modele, ki ne bodo samo razumeli slovenskega jezika, ampak bodo sposobni voditi smiselne in kontekstualno relevantne dialoge, kar bo izboljšalo interakcijo med uporabniki in tehnologijo ter povečalo uporabnost konverzijskih agentov v slovenskem jezikovnem prostoru.

Za nadaljnje izboljšave in prilagoditve naših modelov, bo naša raziskovalna akcija temeljila na zbirki orodij in virov, dostopnih v repozitoriju Brevdev Notebooks. Ta bogat vir

vsebuje obsežno zbirko zvezkov Jupyter, ki ponujajo raznolike metode, tehnike in primere kode, ki so ključni za razumevanje naših modelov.

Ocenjevanje kakovosti forum objave

Na podlagi analize značilnosti, ki jih uporabniki spletnih zdravstvenih forumov upoštevajo pri ocenjevanju verodostojnosti informacij, smo razvili strategijo za filtriranje odgovorov iz forumskih strani, prilagojeno po [6, 7]. Ta strategija vključuje:

1. **Kakovost argumenta** – prednost bodo imeli odgovori, ki so logično utemeljeni in smiselni;
2. **Preverjanje** – informacije bodo preverjene z zunanjimi ali notranjimi viri za dodatno potrditev verodostojnosti;
3. **Pismenost prispevka** – ocenjevali bomo prvi vtis kakovosti sporočila na podlagi pismenosti prispevka, pri čemer bomo upoštevali vpliv fizične in duševne izčrpanosti na sposobnost artikulacije;
4. **Verodostojnost referenc** – prednost bodo imeli odgovori, ki vključujejo verodostojne zunanje reference;
5. **Konsenz množice** – upoštevali bomo splošno mnenje skupnosti in podpora več viri za oceno verodostojnosti. Ta pristop omogoča izločanje manj verodostojnih informacij in izpostavlja tiste, ki ustrezajo našim kriterijem kakovosti, verodostojnosti in objektivnosti.

Results

Use the results section to present the final results of your work. Present the results in a objective and scientific fashion. Use visualisations to convey your results in a clear and efficient manner. When comparing results between various techniques use appropriate statistical methodology.

Discussion

Use the Discussion section to objectively evaluate your work, do not just put praise on everything you did, be critical and exposes flaws and weaknesses of your solution. You can also explain what you would do differently if you would be able to start again and what upgrades could be done on the project in the future.

Acknowledgments

Here you can thank other persons (advisors, colleagues ...) that contributed to the successful completion of your project.

References

- [1] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023.
- [2] Albert Q Jiang, Alexandre Sablayrolles, Antoine Roux, Arthur Mensch, Blanche Savary, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Emma Bou Hanna, Florian Bressand, et al. Mixtral of experts. *arXiv preprint arXiv:2401.04088*, 2024.
- [3] Medovernet - svetovanje. <https://med.over.net/>, 2024. Dostopano: 17.3.2024.
- [4] Vizita.si - za vaše zdravje. <https://vizita.si/>, 2024. Dostopano: 17.3.2024.
- [5] Viva - portal za zdravo življenje. <https://viva.bhc.si/>, 2024. Dostopano: 17.3.2024.
- [6] Hanmei Fan, Reeve Lederman, Stephen Smith, and Shanton Chang. How online health forum users assess user-generated content: Mixed-method research. 2013.
- [7] Madison Elizabeth Sauls. *Perceived Credibility of Information on Internet Health Forums*. Clemson University, 2018.